

演化計算 Hw2

— 0416235 劉昱劭

點擊連結觀看網頁版：<https://hackmd.io/s/r1F1o3dqE>

1.

Discuss why steady-state GAs and ES form two extremes regarding the population size and the number of offspring created.

- 我們知道：
 - mutation 是對單一 individual 的 operator
 - crossover 需要至少兩個 individual
- 最大的差異是產生子代的運算中，crossover 的有無
 - GA (幾乎) 一定有 crossover。
 - ES 可以不要 crossover，主要依靠 mutation。
- ES 產生子代的方式以 mutation 為主，mutation 只要有一個 individual 就可以 work。
 - 因此 ES 的 population size 可以很小，例如 (1+1)-ES 的 population size = 1。
 - 子代的數量通常跟 population size 相同 (一樣小)，因為每個 parent 會 mutate 出一個 offspring。
- GA 產生子代依靠 crossover 和 mutation。
 - 因 crossover 需要多一點 individual 來提供多樣性，以探索 search space 的其他地方，所以 GA 的 population size 會比 ES 大得多。
 - offspring size 大約是 population size 的大小，會比 ES 大得多。

ES 的行為比較像 DFS

GA 的行為比較像 BFS

2.

- 不管 one-point crossover 還是 uniform crossover 都不會改變其 0, 1 出現的 frequency。
- 這種 crossover 可以視為變換 allele 的 combination，只是交換到不同 individual 上，並不會增減 0, 1 的數量。

$$\text{minimize } f(x) = \sum_{i=1}^n x_i^2, \quad x_i \in \mathbb{R}, \quad i = 1, 2, \dots, n$$

3. (1+1)-ES , (1,1)-ES with fixed σ

(1+1)-ES	0.01	0.1	1.0	(1,1)-ES	0.01	0.1	1.0
Run #1	925	259701	∞	Run #1	∞	∞	∞
Run #2	814	263263	∞	Run #2	∞	∞	∞
Run #3	856	27812	∞	Run #3	∞	∞	∞
Run #4	891	726314	∞	Run #4	∞	∞	∞
Run #5	835	5442	∞	Run #5	∞	∞	∞
Run #6	881	899414	∞	Run #6	∞	∞	∞
Run #7	788	27931	∞	Run #7	∞	∞	∞
Run #8	795	141405	∞	Run #8	∞	∞	∞
Run #9	898	216004	∞	Run #9	∞	∞	∞
Run #10	862	139607	∞	Run #10	∞	∞	∞

4. cf. (1+1)-ES , (1,1)-ES

4-1. (1+1)-ES

- 每次 survivor selection 的時候，就能從 parent 和 offspring 之間挑一個 fitness 好的，這件事能讓 population 往 optimum 靠近。
 - 如果 offspring 比 parent 還糟，那表示這個 step 不好，留下 parent，下一代再 mutate 一個新的 step。
 - 但對這個問題來說，step size 給到 1.0 已經太大了，遠大於我們所設的門檻 0.005，(1+1)-ES 同樣收斂不了。
 - 當 step size=1.0，表示每一維的 step 期望值會是 1，很有可能他會在最佳解附近繞圈，但是很難走進我們設定的 threshold 0.005，這麼大的 step size 很容易走超過。
- 由結果可知，此題的 step size 在 0.01 這種量級是最快收斂的，0.1 次之，到 1.0 幾乎已經無法收斂。

4-2. (1,1)-ES

- 可以說是 random search，沒有辦法預測下一代會往哪裡 mutate，也沒辦法保證它會往 optimum 收斂，所以可以看到結果全部收斂不了。

5. (1+1)-ES, (1,1)-ES with self-adapted σ_i

- 參數設定：

- $\tau = 0.1 * \frac{1}{\sqrt{2n}} \approx 0.02$

- $\tau' = \frac{1}{\sqrt{2\sqrt{n}}} \approx 0.3976$

- $\epsilon_0 = 10^{-5}$

(1+1)-ES	0.01	0.1	1.0	(1,1)-ES	0.01	0.1	1.0
Run #1	2120	2294	∞	Run #1	∞	∞	∞
Run #2	2173	2282	∞	Run #2	∞	∞	∞
Run #3	1845	2858	∞	Run #3	∞	∞	∞
Run #4	3122	2133	∞	Run #4	∞	∞	∞
Run #5	4128	2127	∞	Run #5	∞	∞	∞
Run #6	1920	2126	∞	Run #6	∞	∞	∞
Run #7	2161	2129	∞	Run #7	∞	∞	∞
Run #8	3130	2133	∞	Run #8	∞	∞	∞
Run #9	1704	2124	∞	Run #9	∞	∞	∞
Run #10	2133	3088	∞	Run #10	∞	∞	∞

6. cf. 3, 5

- 第五題的方式會有全體 (10 維共同) τ ，跟自己 (每一維) τ' 兩個 learning rate，有可能比較靠近極值的維度，被其他維給拖走，導致整個 individual 無法靠近 optimum。
- 因此我把全體的 learning rate τ 調低，以減少這種現象。

6-1. (1+1)-ES

註：代數 = generation count

- 相較於第三題，可以看到 0.01 所需的代數增加，0.1 則減少。
 - 由第三題的結論推測，這組參數容易把平均的 step size 調至 [0.01, 0.1] 之間。
- 但 step size 初始值是 1 的好像還是 step 過大，無法收斂到半徑 0.005 之內。
- 當 ϵ_0 設過小 ($< 10^{-5}$) 的時候，會增加收斂所需要的代數。

6-2. (1,1)-ES

- 一樣是 random search，無法保證其往極值靠近。



7. 1/5-rule

- 參數設定：
 - $G = 35$
 - $a = 0.89$

(1+1)-ES	0.01	0.1	1.0	(1,1)-ES	0.01	0.1	1.0
Run #1	527	726	1057	Run #1	∞	∞	∞
Run #2	579	623	1123	Run #2	∞	∞	∞
Run #3	516	502	1261	Run #3	∞	∞	∞
Run #4	657	589	1167	Run #4	∞	∞	∞
Run #5	588	627	1114	Run #5	∞	∞	∞
Run #6	666	531	1180	Run #6	∞	∞	∞
Run #7	629	602	1017	Run #7	∞	∞	∞
Run #8	626	489	1081	Run #8	∞	∞	∞
Run #9	534	546	1158	Run #9	∞	∞	∞
Run #10	543	468	1130	Run #10	∞	∞	∞

8. cf. 3, 5, 7

- 這種 self-adapted mutation 比起第五題更能迅速修正。
- 第五題的 n-step mutation 可能會導致不同維互相影響，可能無法有效的靠近 optimum，而 1/5 rule 在一直無法靠近 optimum 的時候 (即 P_s 小)，以減少 step size，避免在 optimum 附近繞圈而進不去門檻內的問題。

8-1. (1,1)-ES

- 因 1-5 rule 可動態伸縮 step size，即使是原本 step size=1 過大，也會慢慢的把 step 調小以致於收斂。
- 而這種比較彈性的 step size 也讓 0.01, 0.1 的 case 更快的收斂到極值。
 - 能用比較大的 step size explore 大範圍的 search space
 - 走到極值附近之後，以小的 step 逼近極值以走進門檻的限制。

8-2. (1,1)-ES

- 一樣是 random search，無法保證其往極值靠近。

